

BotRGCN 论文复现报告

论文题目: BotRGCN: Twitter Bot Detection with Relational Graph Convolutional Networks

论文作者: 冯尚斌、万鹤润、王宁楠、罗敏楠

姓名: 李豆豆

班级: 网安 2502

学号: 2246122390

完成日期: 9.17-9.24

一、解读论文

研究目标	解决 Twitter 上机器人账号过多使数据统计失真的问题
主要内容	利用机器学习方法, 将 Twitter 账号中的真人账号和机器人账号分类, 命名该方法为 BotRGCN。
BotRGCN 方法	将每个 Twitter 用户建模为图的节点, 将关注、转发、提及等行为建模为不同类型的关系, 据此使用 R-GCN 网络对人类账号 (human) 和机器人账号 (bot) 进行分类。
数学方法	机器学习→神经网络→R-GCN 关系图卷积网络
难点	文本特征编码、关系提取建模、模型参数选取

二、实验过程

第一步: 配置环境

该步骤用 agent 辅助完成。具体配置如下:

Python3.13 虚拟环境、PyTorch、PyTorch Geometric、Transformers

第二步: 数据预处理

询问论文作者得到原论文数据集 TwiBot-20, 据此展开复现工作。

1、检查数据

撰写脚本 inspect_support.py 对原始数据进行检查, 训练、验证和测试划分沿用原论文 TwiBot-20 的划分。

2、建立图

对每个用户建立节点 (229,580 个)

根据用户的邻接关系建立边 (两类: following、follower, 共 227,979 条), 关系类型分别映射为 0 和 1。

3、将特征值转化为张量

根据原论文选取出需要的特征，构造论文定义的 6 个数值属性和 11 个类别属性：

数值属性包括 followers、followings、favorites、statuses、active_days 和 screen_name_length，并使用训练集统计量进行 z-score 标准化。

类别属性包括 protected、geo_enabled、verified、contributors_enabled、is_translator、is_translation_enabled、profile_background_tile、profile_user_background_image、has_extended_profile、default_profile 和 default_profile_image。

类别字段按二元 one-hot 值编码后输入全连接层。

4、RoBERTa 文本编码

使用 RoBERTa 编码有标签用户的 description 和 tweets：

{description: 使用 roberta – base 的首个 token 表示
tweets: 逐条使用 RoBERTa 编码，并对用户的全部可用 tweet 表示取平均
没有可用 tweet: 即原始记录为空的用户使用零向量

第三步：BotRGCN 主实验

BotRGCN 由多模态特征编码模块、关系图卷积模块和分类模块组成。

首先，将 description、tweets、数值属性和类别属性分别经过全连接层，映射到用户表示维度的四分之一，随后进行拼接，得到图神经网络的初始节点表示：

$$r_i = [r_i^d \text{description}; r_i^t \text{tweets}; r_i^n \text{um}; r_i^c \text{at}]$$

随后，使用两层 R-GCN，对 following 和 follower 两种关系分别使用关系相关参数进行邻居聚合。R-GCN 输出再经过论文描述的 MLP 投影层和 Leaky-ReLU，最后通过分类层输出用户为 bot 的预测概率。

训练目标采用论文中的二元交叉熵损失，并使用 Adam 优化器的 weight decay 实现 L2 正则化。当前实验配置为：

表 1：主实验参数表

参数	值
隐藏表示维度	D=64
学习率	1e-3
weight decay	5e-4

参数	值
最大训练轮数	100
根据验证集 F1 进行 early stopping 的 patience	20
随机种子	42、43、44

需要注意的是，由于论文正文未完整公开隐藏维度、学习率、训练轮数、早停策略等全部训练参数，因此上述参数并未完全与论文保持一致。

表 2：主实验结果表

指标	均值 ± 标准差
Accuracy	0.8166 ± 0.0009
Precision	0.7509 ± 0.0014
Recall	0.9891 ± 0.0054
F1	0.8537 ± 0.0012
MCC	0.6633 ± 0.0042

表 3：复现实验结果与原论文比较表

指标	论文结果	本复现	差值
Accuracy	0.8462	0.8166	-0.0296
F1	0.8707	0.8537	-0.0170
MCC	0.7021	0.6633	-0.0388

本复现的 F1 和 MCC 低于原论文报告值，但三次运行的 F1 标准差为 0.0012，说明当前实现具有稳定的重复性。与原论文差异可能来自未公开的隐藏维度、优化器参数、训练策略和具体 RoBERTa 处理细节等因素。

第四步：消融实验

（一）特征消融实验

表 4：特征属性消融实验结果表

配置	Accuracy	F1	MCC
完整特征	0.8155 ± 0.0010	0.8528 ± 0.0012	0.6611 ± 0.0040
去除 description	0.8163 ± 0.0022	0.8536 ± 0.0018	0.6633 ± 0.0054
去除 tweets	0.8177 ± 0.0013	0.8544 ± 0.0006	0.6652 ± 0.0021
去除数值属性	0.8157 ± 0.0009	0.8533 ± 0.0009	0.6627 ± 0.0033
去除类别属性	0.6915 ± 0.0400	0.7549 ± 0.0142	0.3885 ± 0.0669
仅保留属性	0.6205 ± 0.0688	0.6842 ± 0.0155	0.2137 ± 0.1851

由上表发现，完整模型的 F1 约为 0.8530。其中，类别属性十分重要，去除后 F1 从约 0.853 降至约 0.754。另外，仅保留属性特征时模型的性能明显下降，而单独去除 description 或 tweets 后，F1 没有下降，反而略有上升。这说明文本特征和图结构的共同作用十分显著，也证明了图结构的必要性。

（二）关系消融实验

表 5：关系类型消融实验结果表

关系类型	Accuracy	F1	MCC
all	0.8163 ± 0.0005	0.8536 ± 0.0005	0.6633 ± 0.0016

关系类型	Accuracy	F1	MCC
following	0.7681 ± 0.0788	0.8169 ± 0.0605	0.5590 ± 0.1733
follower	0.8163 ± 0.0022	0.8541 ± 0.0017	0.6654 ± 0.0049

如上表所示，follower 与 all 的 F1 几乎相同，而 following 单独使用时性能明显下降，说明 following 关系可能较稀疏、噪声更大，单独使用会降低性能。

第五步：基线实验

在相同多模态输入和 BCE 训练协议下，MLP、GCN、GAT 的三次种子结果如下：

表 6：基线实验结果表

模型	Accuracy	F1	MCC
MLP	0.8169 ± 0.0005	0.8550 ± 0.0003	0.6688 ± 0.0010
GCN	0.5900 ± 0.0301	0.7139 ± 0.0092	0.1831 ± 0.0743
GAT	0.5424 ± 0.0024	0.7026 ± 0.0009	0.0205 ± 0.0356
BotRGCN	0.8166 ± 0.0009	0.8537 ± 0.0012	0.6633 ± 0.0042

由表可知，GCN 和 GAT 的结果明显较低，但 MLP 的结果略高于 BotRGCN，这可能是原论文与本次复现实验的参数选取等差异导致的。

四、实验小结

本次复现实验基本完成了原论文的实验内容，在原论文的数据集上构造了 BotRGCN 并加以训练，并在主实验后进行了消融实验和基线实验。

在未完全获知原论文全部训练细节的情况下，本复现实验获得 $F1=0.8537 \pm 0.0012$ ，较论文报告值 0.8707 低 0.0170；同时完成特征消融、关系消融和 MLP/GCN/GAT 基线实验。结果表明复现实验具有较好的重复稳定性，但图结构相对于 MLP 的额外收益尚未得到充分验证，后续还可以进一步改进以提升实验结果。

五、我的收获

通过本次复现实验，我在数据处理、模型理解和科研复现论文等方面有所收获，具体如下：

第一，掌握了从原始 JSON 数据构建大规模异构用户图的方法，包括节点 ID 对齐、关系类型编码、边索引生成以及 train/dev/test mask 构造。这一过程使我理解了如何将原始社交关系数据转化为图神经网络可用的异构图结构，并保证不同关系类型正确表示。

第二，理解了论文中的多模态用户表示方法。用户特征并非单一来源，而是由 RoBERTa 文本语义特征、数值属性和类别属性分别编码后再进行融合。我认识到不同模态特征在用户表示中承担不同作用，也理解了多模态融合对于提升用户建模能力的重要性。

第三，掌握了 RoBERTa 文本编码的工程实现流程，包括分块、断点续跑、特征合并和有限值检查。在实际处理 support 数据时，遇到了数据规模大、文本为空、GPU 显存受限和耗时过长等问题，通过分块编码和断点续跑等策略逐步解决。这让我认识到，大规模文本特征提取不仅依赖模型本身，也依赖稳定、可恢复的工程流程。

第四，理解了 R-GCN 如何使用 relation-specific 参数区分 following 和 follower 两类关系，并完成了关系消融和基线对比。通过实验，我进一步认识到关系类型建模对图神经网络性能的影响，也学会了利用消融实验验证不同信息的作用。

第五，通过将主实验与论文结果对照，我认识到复现论文不仅是跑通代码，还包括数据一致性、指标定义、随机种子稳定性和差异分析。只有在这些方面进行系统检查，才能判断复现结果与论文结果之间的差异来源，并形成可靠的实验结论。

五、完成时间表

表 7：完成时间表

时间	工作
9.18	阅读论文并读懂
9.19-9.20	搜集数据集
9.21	获得原作者给的数据集并进行数据预处理
9.21-9.22	RoBERTa 文本编码
9.23	主实验模型训练
9.24-9.25	完成消融实验与报告撰写

附录

一、核心代码清单

表 2：核心代码清单表

文件	功能
scripts/build_node_index.py	构造全量节点 ID 到连续索引
scripts/build_full_edges.py	扫描 train/dev/test/support 并构图
scripts/build_paper_property_features.py	构造 6 个数值属性和 11 个类别属性
scripts/encode_labeled_roberta.py	编码有标签用户文本
scripts/encode_support_roberta.py	分块编码 support 文本
scripts/merge_support_roberta_chunks.py	合并 support chunk
scripts/validate_full_features.py	验证形状、有限值和 mask
scripts/train_botrgcn_official.py	正式 BotRGCN 主实验
scripts/train_botrgcn_ablation.py	特征与关系消融
scripts/train_baselines.py	MLP、GCN、GAT 基线

二、关键数据产物

表 2：关键数据清单表

文件	内容	形状/数量
processed/full_node_index.json	节点 ID 映射	229580 节点

文件	内容	形状/数量
processed/edge_index.pt	边索引	2×227979
processed/edge_type.pt	关系类型	227979
processed/x_paper_properties.pt	论文属性特征	229580×17
processed/description_roberta_full.pt	description 表示	229580×768
processed/tweet_roberta_full.pt	tweet 平均表示	229580×768
processed/y_full.pt	标签	229580
processed/train_mask.pt	训练 mask	8278
processed/val_mask.pt	验证 mask	2365
processed/test_mask.pt	测试 mask	1183